Implementacja wydajnych struktur danych do praktycznych operacji na słowach

(Implementation of efficient data structures for practical string operations)

Michał Górniak

Instytut Informatyki Uniwersytetu Wrocławskiego

11 września 2020

Chcemy utrzymywać dynamiczny zbiór słów \mathcal{S} .

Chcemy utrzymywać dynamiczny zbiór słów \mathcal{S} .

Słowa w tym słowniku będą mogły być bardzo długie, więc przy dodawaniu nowych słów, będziemy dostawać od programu etykietę ℓ , dzięki której będziemy mogli łatwo odwoływać się do wybranych słów.

Chcemy utrzymywać dynamiczny zbiór słów \mathcal{S} .

Słowa w tym słowniku będą mogły być bardzo długie, więc przy dodawaniu nowych słów, będziemy dostawać od programu etykietę ℓ , dzięki której będziemy mogli łatwo odwoływać się do wybranych słów.

Oznaczmy przez $\mathcal{W}(\ell)$ słowo reprezentowane przez etykietę $\ell.$

Chcemy utrzymywać dynamiczny zbiór słów \mathcal{S} .

Słowa w tym słowniku będą mogły być bardzo długie, więc przy dodawaniu nowych słów, będziemy dostawać od programu etykietę ℓ , dzięki której będziemy mogli łatwo odwoływać się do wybranych słów.

Oznaczmy przez $\mathcal{W}(\ell)$ słowo reprezentowane przez etykietę $\ell.$

W każdym momencie możemy modyfikować słownik lub zadawać zapytania:

- make_string(w) $S := S \cup \{w\}$,
- $concat(\ell_1,\ell_2) \mathcal{S} := \mathcal{S} \cup \{\mathcal{W}(\ell_1)\mathcal{W}(\ell_2)\},\$
- $\operatorname{split}(\ell,p)$ $\mathcal{S}\coloneqq\mathcal{S}\cup\{\mathcal{W}(\ell)_{\ldots p},\mathcal{W}(\ell)_{(p+1)\ldots}\}$,

Chcemy utrzymywać dynamiczny zbiór słów $\mathcal{S}.$

Słowa w tym słowniku będą mogły być bardzo długie, więc przy dodawaniu nowych słów, będziemy dostawać od programu etykietę ℓ , dzięki której będziemy mogli łatwo odwoływać się do wybranych słów.

Oznaczmy przez $\mathcal{W}(\ell)$ słowo reprezentowane przez etykietę $\ell.$

W każdym momencie możemy modyfikować słownik lub zadawać zapytania:

- make_string $(w) S := S \cup \{w\}$,
- $concat(\ell_1, \ell_2) \mathcal{S} := \mathcal{S} \cup \{\mathcal{W}(\ell_1)\mathcal{W}(\ell_2)\},\$
- $\bullet \ \mathtt{split}(\ell, p) \mathcal{S} \coloneqq \mathcal{S} \cup \{\mathcal{W}(\ell)_{\dots p}, \mathcal{W}(\ell)_{(p+1)\dots}\},$
- equals (ℓ_1,ℓ_2) zwróć $\mathcal{W}(\ell_1)=\mathcal{W}(\ell_2)$,
- smaller (ℓ_1,ℓ_2) zwróć $\mathcal{W}(\ell_1) <_{\mathsf{lex}} \mathcal{W}(\ell_2)$,
- $lcp(\ell_1, \ell_2)$ zwróć najdłuższy wspólny prefiks $W(\ell_1)$ i $W(\ell_2)$.

Tabela złożoności (modyfikacje słownika)

Niech *n* oznacza długość słowa, które jest podane jako pierwszy argument funkcji.

Tabela złożoności (modyfikacje słownika)

Niech n oznacza długość słowa, które jest podane jako pierwszy argument funkcji.

Niech m oznacza długość słowa, które jest podane jako drugi argument funkcji (jeśli istnieje).

Tabela złożoności (modyfikacje słownika)

Niech n oznacza długość słowa, które jest podane jako pierwszy argument funkcji.

Niech m oznacza długość słowa, które jest podane jako drugi argument funkcji (jeśli istnieje).

Rozwiązanie	make_string	concat	split
Naiwne	deterministyczna $\mathcal{O}(n)$	deterministyczna $\mathcal{O}(n+m)$	deterministyczna $\mathcal{O}(n)$
Drzewce	oczekiwana $\mathcal{O}(n)$	oczekiwana $\mathcal{O}(\log(n+m))$	oczekiwana $\mathcal{O}(\log n)$
Parsingi	oczekiwana $\mathcal{O}(n)$	oczekiwana $\mathcal{O}(\log(n+m))$	oczekiwana $\mathcal{O}(\log n)$
Gawrychowski et al.	$\mathcal{O}(n)$ w.h.p.	$\mathcal{O}(\log(n+m))$ w.h.p.	$\mathcal{O}(\log n)$ w.h.p.
Mehlhorn et al.	deterministyczna $\mathcal{O}(n)$	$ \frac{deterministyczna}{\mathcal{O}(\log^2(n+m)\log^*(n+m))} $	$deterministyczna \\ \mathcal{O}(\log^2 n \log^* n)$
Alstrup et al.	$\mathcal{O}(n)$ w.h.p.	$\mathcal{O}(\log(n+m)\log^*(n+m))$ w.h.p.	$\mathcal{O}(\log n \log^* n)$ w.h.p.

Tabela złożoności (zapytania do struktury)

Rozwiązanie	equals	smaller	lcp
Naiwne	deterministyczna	deterministyczna	deterministyczna
	$\mathcal{O}(\min(n,m))$	$\mathcal{O}(\min(n,m))$	$\mathcal{O}(\min(n,m))$
Drzewce	Monte Carlo	Monte Carlo	Monte Carlo
Dizewce	$\mathcal{O}(1)$	$\mathcal{O}(\log^2(n+m))$	$\mathcal{O}(\log^2(n+m))$
Parsingi	deterministyczna	oczekiwana	oczekiwana
Farsingi	$\mathcal{O}(1)$	$\mathcal{O}(\log(n+m))$	$\mathcal{O}(\log(n+m))$
Davainai (walna 1)	deterministyczna	oczekiwana	oczekiwana
Parsingi (wolne 1cp)	$\mathcal{O}(1)$	$\mathcal{O}(\log^2(n+m))$	$\mathcal{O}(\log^2(n+m))$
Gawrychowski et al.	deterministyczna	deterministyczna	deterministyczna
Gawrychowski et al.	$\mathcal{O}(1)$	$\mathcal{O}(1)$	$\mathcal{O}(1)$
Mehlhorn et al.	deterministyczna		
	$\mathcal{O}(1)$		
Alstrup et al.	deterministyczna	deterministyczna	deterministyczna
	$\mathcal{O}(1)$	$\mathcal{O}(1)$	$\mathcal{O}(1)$

Struktura kodu

Kod został podzielony na trzy główne części:

Struktura kodu

Kod został podzielony na trzy główne części:

• pliki run.cpp i makefile

Struktura kodu

Kod został podzielony na trzy główne części:

- pliki run.cpp i makefile
- folder solutions/

Struktura kodu

Kod został podzielony na trzy główne części:

- pliki run.cpp i makefile
- folder solutions/
- folder testers/

Struktura kodu

Kod został podzielony na trzy główne części:

- pliki run.cpp i makefile
- folder solutions/
- folder testers/

Interfejs abstrakcyjnej klasy solution.h

```
class solution {
  public:
    virtual ~solution() = 0;

    virtual int make_string(std::vector<int> &word) = 0;

    virtual int concat(int label1, int label2) = 0;

    virtual std::pair<int, int> split(int label, int position) = 0;

    virtual bool equals(int label1, int label2) = 0;

    virtual bool smaller(int label1, int label2) = 0;

    virtual int longest_common_prefix(int label1, int label2) = 0;

};
```

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

Używamy drzew zbalansowanych, tak aby można było:

• łączyć dwa drzewa i dzielić jedno w czasie logarytmicznym,

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

- łączyć dwa drzewa i dzielić jedno w czasie logarytmicznym,
- w każdym wierzchołku trzymać hasz całego jego poddrzewa,

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

- łączyć dwa drzewa i dzielić jedno w czasie logarytmicznym,
- w każdym wierzchołku trzymać hasz całego jego poddrzewa,
- porównywać hasze wybranych wierzchołków dla sprawdzenia =,

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

- łączyć dwa drzewa i dzielić jedno w czasie logarytmicznym,
- w każdym wierzchołku trzymać hasz całego jego poddrzewa,
- porównywać hasze wybranych wierzchołków dla sprawdzenia =,
- ullet wyszukiwać binarnie po wyniku, aby wyliczać 1cp i $<_{\mathrm{lex}}.$

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

Używamy drzew zbalansowanych, tak aby można było:

- łączyć dwa drzewa i dzielić jedno w czasie logarytmicznym,
- w każdym wierzchołku trzymać hasz całego jego poddrzewa,
- porównywać hasze wybranych wierzchołków dla sprawdzenia =,
- ullet wyszukiwać binarnie po wyniku, aby wyliczać 1cp i $<_{\mathrm{lex}}.$

Rotacje

Implementacja drzewców nie wymaga implementacji rotacji drzewa. Drzewo musi zachowywać porządek kopcowy patrząc na priorytety, a porządek BST patrząc na klucze. W ten sposób zawsze powstaje **dokładnie** jeden drzewiec.

Każde drzewo zbalansowane reprezentuje jedno słowo ze słownika.

Używamy drzew zbalansowanych, tak aby można było:

- łączyć dwa drzewa i dzielić jedno w czasie logarytmicznym,
- w każdym wierzchołku trzymać hasz całego jego poddrzewa,
- porównywać hasze wybranych wierzchołków dla sprawdzenia =,
- ullet wyszukiwać binarnie po wyniku, aby wyliczać 1cp i $<_{\text{lex}}.$

Rotacje

Implementacja drzewców nie wymaga implementacji rotacji drzewa. Drzewo musi zachowywać porządek kopcowy patrząc na priorytety, a porządek BST patrząc na klucze. W ten sposób zawsze powstaje **dokładnie** jeden drzewiec.

Przykład

W kolejnym slajdzie opiszemy działanie funkcji merge.

Operacja merge (teoria)

Przykład

Załóżmy, że chcemy złączyć drzewce A oraz B i bez straty ogólności A ma większy priorytet w korzeniu niż B.

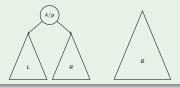




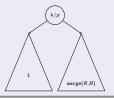
Operacja merge (teoria)

Przykład

Załóżmy, że chcemy złączyć drzewce A oraz B i bez straty ogólności A ma większy priorytet w korzeniu niż B.



Wystarczy zatem wywołać rekurencyjnie merge(R, B) i podpiąć odpowiednio wskaźniki.



Operacja merge (implementacja)

```
balanced_trees::treap *balanced_trees::merge(balanced_trees::treap *t1,
                                                  balanced trees::treap *t2) {
3
       if (t1 == nullptr) {
4
           return t2:
5
6
       if (t2 == nullptr) {
7
           return t1;
8
       if (t1->priority > t2->priority) {
           auto return_treap = new treap(*t1);
10
           return treap->right subtree = merge(t1->right subtree, t2):
11
12
           update_values(return_treap);
13
           return return_treap;
14
       } else {
15
           auto return_treap = new treap(*t2);
           return_treap->left_subtree = merge(t1, t2->left_subtree);
16
17
           update values (return treap):
18
           return return_treap;
19
20 ]
```

Fakty o drzewcach

Operacja merge (implementacja)

```
balanced_trees::treap *balanced_trees::merge(balanced_trees::treap *t1,
                                                  balanced trees::treap *t2) {
3
       if (t1 == nullptr) {
4
           return t2:
6
       if (t2 == nullptr) {
7
           return t1;
8
       if (t1->priority > t2->priority) {
10
           auto return_treap = new treap(*t1);
           return treap->right subtree = merge(t1->right subtree, t2):
11
12
           update_values(return_treap);
13
           return return_treap;
14
       } else {
15
           auto return_treap = new treap(*t2);
           return_treap->left_subtree = merge(t1, t2->left_subtree);
16
17
           update values (return treap):
18
           return return_treap;
19
20 ]
```

Fakty o drzewcach

mają wysokość logarytmiczną w.h.p.

Operacja merge (implementacja)

```
balanced_trees::treap *balanced_trees::merge(balanced_trees::treap *t1,
                                                  balanced trees::treap *t2) {
       if (t1 == nullptr) {
           return t2:
6
       if (t2 == nullptr) {
7
           return t1;
8
       if (t1->priority > t2->priority) {
10
           auto return_treap = new treap(*t1);
           return treap->right subtree = merge(t1->right subtree, t2):
11
12
           update_values(return_treap);
13
           return return_treap;
14
       } else {
15
           auto return_treap = new treap(*t2);
           return_treap->left_subtree = merge(t1, t2->left_subtree);
16
17
           update values (return treap):
18
          return return_treap;
19
20
```

Fakty o drzewcach

- mają wysokość logarytmiczną w.h.p.
- porównywanie podsłów również jest w.h.p. (hasze Karpa-Rabina)

Utrzymujemy dynamiczną gramatykę bezkontekstową bez symbolu startowego.

Utrzymujemy dynamiczną gramatykę bezkontekstową bez symbolu startowego.

Każdy symbol generuje dokładnie jedno słowo.

Utrzymujemy dynamiczną gramatykę bezkontekstową bez symbolu startowego.

Każdy symbol generuje dokładnie jedno słowo.

Każdy symbol ma przypisany poziom, na którym występuje. Symbole powstają podczas tworzenia *drzewa symbolu* nad nowym słowem.

Utrzymujemy dynamiczną gramatykę bezkontekstową bez symbolu startowego.

Każdy symbol generuje dokładnie jedno słowo.

Każdy symbol ma przypisany poziom, na którym występuje. Symbole powstają podczas tworzenia *drzewa symbolu* nad nowym słowem.

Tworzenie drzewa symbolu

Polega na naprzemiennym wykonywaniu kompresji typu:

Utrzymujemy dynamiczną gramatykę bezkontekstową bez symbolu startowego.

Każdy symbol generuje dokładnie jedno słowo.

Każdy symbol ma przypisany poziom, na którym występuje. Symbole powstają podczas tworzenia *drzewa symbolu* nad nowym słowem.

Tworzenie drzewa symbolu

Polega na naprzemiennym wykonywaniu kompresji typu:

• RLE (run-length encoding),

Utrzymujemy dynamiczną gramatykę bezkontekstową bez symbolu startowego.

Każdy symbol generuje dokładnie jedno słowo.

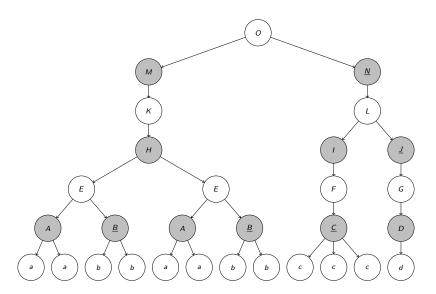
Każdy symbol ma przypisany poziom, na którym występuje. Symbole powstają podczas tworzenia *drzewa symbolu* nad nowym słowem.

Tworzenie drzewa symbolu

Polega na naprzemiennym wykonywaniu kompresji typu:

- RLE (run-length encoding),
- SHRINK, która zależy od losowych bitów symboli.

Przykładowe drzewo symbolu



Twierdzenie o oczekiwanym czasie budowy drzewa symbolu

Twierdzenie

Oczekiwany czas budowy drzewa nad słowem długości n, wynosi $\mathcal{O}(n)$.

Twierdzenie

Oczekiwany czas budowy drzewa nad słowem długości n, wynosi $\mathcal{O}(n)$.

Fakt z pracy Optimal Dynamic Strings

Po zastosowaniu kompresji typu RLE, a następnie kompresji typu SHRINK na dowolnym słowie w, oczekiwana długość słowa w' powstałego w wyniku kompresji jest nie większa niż $\frac{3}{4}|w|+\frac{1}{4}$.

Twierdzenie

Oczekiwany czas budowy drzewa nad słowem długości n, wynosi $\mathcal{O}(n)$.

Fakt z pracy Optimal Dynamic Strings

Po zastosowaniu kompresji typu RLE, a następnie kompresji typu SHRINK na dowolnym słowie w, oczekiwana długość słowa w' powstałego w wyniku kompresji jest nie większa niż $\frac{3}{4}|w|+\frac{1}{4}$.

Szkic dowodu

Twierdzenie

Oczekiwany czas budowy drzewa nad słowem długości n, wynosi $\mathcal{O}(n)$.

Fakt z pracy Optimal Dynamic Strings

Po zastosowaniu kompresji typu RLE, a następnie kompresji typu SHRINK na dowolnym słowie w, oczekiwana długość słowa w' powstałego w wyniku kompresji jest nie większa niż $\frac{3}{4}|w|+\frac{1}{4}$.

Szkic dowodu

• indukcja względem długości słowa,

Twierdzenie

Oczekiwany czas budowy drzewa nad słowem długości n, wynosi $\mathcal{O}(n)$.

Fakt z pracy Optimal Dynamic Strings

Po zastosowaniu kompresji typu RLE, a następnie kompresji typu SHRINK na dowolnym słowie w, oczekiwana długość słowa w' powstałego w wyniku kompresji jest nie większa niż $\frac{3}{4}|w|+\frac{1}{4}$.

Szkic dowodu

- indukcja względem długości słowa,
- wykorzystanie powyższego faktu wraz z nierównością Markowa, aby oszacować prawdopodobieństwo, że długość słowa po dwóch kolejnych fazach kompresji skróci się przez stały czynnik.

Motywacja

Nie możemy w prosty sposób (podobnie jak w drzewach zbalansowanych) łączyć dwóch drzew symboli.

Motywacja

Nie możemy w prosty sposób (podobnie jak w drzewach zbalansowanych) łączyć dwóch drzew symboli.

Okazuje się jednak, że możemy zawsze znaleźć pewną warstwę drzewa symbolu, której RLE jest długości logarytmicznej i jest ona typu context-insensitive.

Motywacja

Nie możemy w prosty sposób (podobnie jak w drzewach zbalansowanych) łączyć dwóch drzew symboli.

Okazuje się jednak, że możemy zawsze znaleźć pewną warstwę drzewa symbolu, której RLE jest długości logarytmicznej i jest ona typu context-insensitive.

Łączenie słów

Motywacja

Nie możemy w prosty sposób (podobnie jak w drzewach zbalansowanych) łączyć dwóch drzew symboli.

Okazuje się jednak, że możemy zawsze znaleźć pewną warstwę drzewa symbolu, której RLE jest długości logarytmicznej i jest ona typu context-insensitive.

Łączenie słów

Szukamy dekompozycji obu słów, a następnie je łączymy.

Motywacja

Nie możemy w prosty sposób (podobnie jak w drzewach zbalansowanych) łączyć dwóch drzew symboli.

Okazuje się jednak, że możemy zawsze znaleźć pewną warstwę drzewa symbolu, której RLE jest długości logarytmicznej i jest ona typu context-insensitive.

Łączenie słów

- Szukamy dekompozycji obu słów, a następnie je łączymy.
- 2 Lista ta będzie dekompozycją konkatenacji początkowych dwóch słów.

Motywacja

Nie możemy w prosty sposób (podobnie jak w drzewach zbalansowanych) łączyć dwóch drzew symboli.

Okazuje się jednak, że możemy zawsze znaleźć pewną warstwę drzewa symbolu, której RLE jest długości logarytmicznej i jest ona typu context-insensitive.

Łączenie słów

- Szukamy dekompozycji obu słów, a następnie je łączymy.
- 2 Lista ta będzie dekompozycją konkatenacji początkowych dwóch słów.
- Budujemy górną część drzewa symbolu, jak przy budowaniu od liści.

Motywacja

Nie możemy w prosty sposób (podobnie jak w drzewach zbalansowanych) łączyć dwóch drzew symboli.

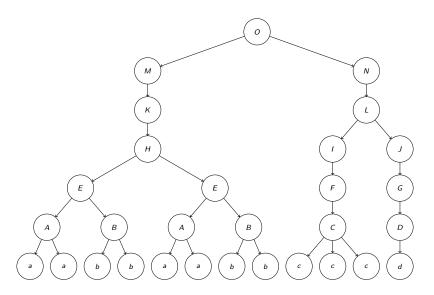
Okazuje się jednak, że możemy zawsze znaleźć pewną warstwę drzewa symbolu, której RLE jest długości logarytmicznej i jest ona typu context-insensitive.

Łączenie słów

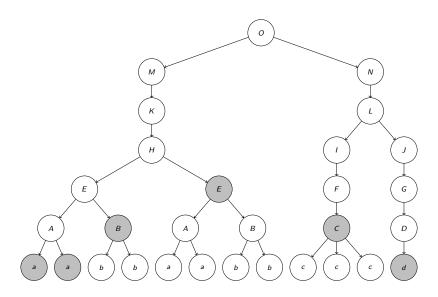
- Szukamy dekompozycji obu słów, a następnie je łączymy.
- 2 Lista ta będzie dekompozycją konkatenacji początkowych dwóch słów.
- Budujemy górną część drzewa symbolu, jak przy budowaniu od liści.

Dzielenie polega na wybraniu dekompozycji typu context-insensitive wybranego podsłowa i zbudowaniu nad nią drzewa symbolu.

Przykład dekompozycji



Przykład dekompozycji



Ze względu na zaawansowanie struktury opisanej w pracy, przyjmujemy pewne uproszczenia.

Ze względu na zaawansowanie struktury opisanej w pracy, przyjmujemy pewne uproszczenia.

Główne różnice w implementacji względem oryginalnej pracy:

• przy budowie drzewa dopuszczamy jednoelementowe produkcje,

Ze względu na zaawansowanie struktury opisanej w pracy, przyjmujemy pewne uproszczenia.

Główne różnice w implementacji względem oryginalnej pracy:

- przy budowie drzewa dopuszczamy jednoelementowe produkcje,
- użycie std::unordered_map, która działa w oczekiwanym czasie stałym,

Ze względu na zaawansowanie struktury opisanej w pracy, przyjmujemy pewne uproszczenia.

Główne różnice w implementacji względem oryginalnej pracy:

- przy budowie drzewa dopuszczamy jednoelementowe produkcje,
- użycie std::unordered_map, która działa w oczekiwanym czasie stałym,
- ullet nie zaimplementowano najlepszej metody dla zapytania 1cp i $<_{\mathsf{lex}}$,

Ze względu na zaawansowanie struktury opisanej w pracy, przyjmujemy pewne uproszczenia.

Główne różnice w implementacji względem oryginalnej pracy:

- przy budowie drzewa dopuszczamy jednoelementowe produkcje,
- użycie std::unordered_map, która działa w oczekiwanym czasie stałym,
- ullet nie zaimplementowano najlepszej metody dla zapytania 1cp i $<_{\text{lex}}$,
- większość operacji traci złożoność w.h.p. na rzecz oczekiwanej.

Ze względu na zaawansowanie struktury opisanej w pracy, przyjmujemy pewne uproszczenia.

Główne różnice w implementacji względem oryginalnej pracy:

- przy budowie drzewa dopuszczamy jednoelementowe produkcje,
- użycie std::unordered_map, która działa w oczekiwanym czasie stałym,
- ullet nie zaimplementowano najlepszej metody dla zapytania 1cp i $<_{ extsf{lex}},$
- większość operacji traci złożoność w.h.p. na rzecz oczekiwanej.

Wysokość drzewa

Faktem pozostaje natomiast logarytmiczna wysokość drzewa w.h.p.

Przykładowe uruchomienie

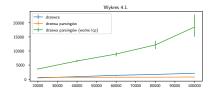
Przykład

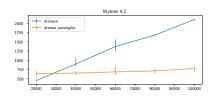
Wywołanie ./run 129873 correctness 1.

Wydruk z terminala

Wykresy czasów działania

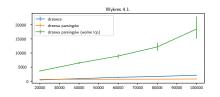
Testy z tablicą sufiksową.

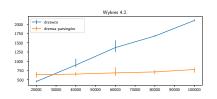




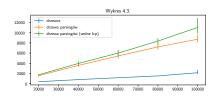
Wykresy czasów działania

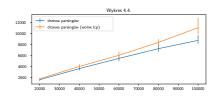
Testy z tablicą sufiksową.





Testy z losowymi poprawnymi operacjami na słowniku.





Dziękuję za uwagę.